

## 1. Miksi RNN-verkkoja käytetään usein luonnollisen kielen käsittelyssä?

RNN-verkot eli rekursiiviset neuroverkot sopivat hyvin luonnollisen kielen käsittelyyn, koska ne on suunniteltu käsittelemään sarjallista eli peräkkäistä dataa. Kieli rakentuu sanoista, jotka tulevat tietyssä järjestyksessä, ja lauseen merkitys riippuu usein siitä, mitä sanoja on aiemmin esiintynyt. RNN soveltuu luonnollisen kielen käsittelyyn koska se pystyy ”muistamaan” aikaisempia sanoja ja hyödyntämään tätä tietoa, kuten videon esimerkissä käsiteltiin.

RNN-verkkojen etuna on myös se, että ne pystyvät käsittelemään vaihtelevan pituisia tekstejä. Tavalliset neuroverkot vaativat kiinteän pituisen syötteen, mutta RNN mukautuu lyhyisiin ja pitkiin lauseisiin. Tämä tekee siitä sopivan monenlaisiin luonnollisen kielen tehtäviin, kuten kielen kääntämisen toiselle, tekstin luomiseen ja kysymyksiin vastaamiseen.

RNN-verkkoja käytetäänkin monimutkaisemmissa kielisovelluksissa, joissa tarvitaan kontekstin ymmärtämistä pidemmällä aikavälillä. Esimerkiksi kielen kääntämisessä sanat eivät aina vastaa toisiaan yksi yhteen eri kielissä, ja RNN pystyy huomioimaan pidempiä yhteyksiä tekstissä. Tämän vuoksi se on luonnollisen kielen käsittelyssä keskeisimmistä neuroverkkotyypeistä.

## 2. Mitä ajatuksia video herätti?

RNN-verkkojen monipuolisuus ja muisti yllätti itseni – niitä ei käytetä pelkästään tekstin käsittelyssä, vaan myös esimerkiksi itseohjautuvissa autoissa, lääketieteellisissä diagnooseissa ja talouden ennusteissa. Tämä osoittaa, että ne soveltuvat hyvin monenlaisiin tehtäviin, joissa tarvitaan aikaisemman tiedon muistamista ja sen pohjalta ennustamista.

Toinen tärkeä huomio liittyi neuroverkkojen koulutuksen haasteisiin. Videolla puhuttiin siitä, kuinka RNN-verkkojen opettaminen voi olla vaikeaa, koska niissä esiintyy ongelmia, kuten ”häviävät” tai ”räjähtävät” gradientit. Tämä tarkoittaa, että oppiminen voi joko pysähtyä tai muuttua epävakaa. Videon perusteella ongelmaan on kehitetty ratkaisuja, kuten LSTM-verkot, jotka parantavat RNN:n muistikykyä ja tekevät siitä täten tehokkaamman.

LSTM-verkkojen toimintaperiaate oli yksi kiinnostavimmista asioista. Niiden kyky unohtaa ja muistaa tietoa hallitusti tekee niistä erityisen hyödyllisiä pitkäkestoisten yhteyksien oppimisessa. Tämä on tärkeää esimerkiksi silloin, kun tekstissä viitataan aikaisemmin mainittuihin asioihin, ja neuroverkon täytyy muistaa ne oikein.

Neuroverkkojen hienosäätö vaikutti myös kiinnostavalta mutta samalla haastavalta prosessilta, ja sai pohtimaan tulevien tehtävien vaativuutta. Videon perusteella oikeiden asetusten löytäminen on usein kokeilua. Tämä vahvistaa aikaisempaan käsitystäni siitä, että neuroverkkojen kehittäminen ei ole pelkkää matemaattista laskemista, vaan myös kokeilemista ja säätämistä - todellista insinöörityötä, jossa tulee paremmaksi tekemisen myötä.

### **3. Mikä jäi epäselväksi?**

Vaikka video antoi sinällään hyvän yleiskuvan RNN-verkoista, joitakin asioita olisi voinut käsitellä ehkä hieman syvällisemmin. Toisaalta video oli luento jonka tarkoituksena onkin jättää asioita opiskelijoiden itse tutkittavaksi syvällisemmin. Itse olisin toivonut kuitenkin LSTM-solun vielä tarkempaa kuvausta. Videolla käytiin läpi sen perusperiaate, mutta olisi ollut hyödyllistä nähdä yksityiskohtaisesti, miten sen eri osat vaikuttavat datan käsittelyyn, vaikka pienen koodin pätkän kautta.

Toiseksi olisi ollut hyödyllistä saada käytännön ohjeita siitä, miten neuroverkon parametreja tulisi säätää. Vaikka videolla puhuttiin parametrien hienosäädöstä, siinä ei annettu konkreettisia neuvoja esimerkiksi siitä, miten oppimismisnopeus tai piilokerrosten määrä kannattaa valita.

Kaiken kaikkiaan video tarjosi mielenkiintoisen hyvän yleiskuvan RNN-verkoista ja niiden käytöstä.